原创性与资源使用声明

四节声明，逐条对应到可点验的产物

赛道 04 AI Agent · 2026-10-23 定稿

作品名称	FailBound-Lab：科研 Agent 的能力边界标定（验证场：材料信息学）
参赛赛道	04 AI Agent
团队	Verity（单人参赛）
声明日期	2026-10-17（最后一次同步：2026-10-23，随提交材料一并冻结）

一、一句话原创性陈述

本作品的**科学问题、实验设计、全部代码、全部数据产物与全部结论，均在赛事期间（2026-10-15 起）从零完成**，无任何赛前既有成果直接带入。参赛者赛前的个人背景（无人机方向工程经验与论文）与本作品在**问题域、代码库、数据集、结论四个维度上完全不重叠**，逐维切割见第三节。

本声明的写法：第四节把每一条声明都绑定到一个可点验的产物文件。我们不需要评审相信这段文字，只需要评审愿意抽查其中任意一行。

二、资源使用清单

2.1 数据（全部为公开基准，未使用任何私有或未授权数据）

数据集	版本 / 来源	用途	许可说明
matbench v0.1	Dunn et al., 2020，公开基准	真实材料体系的描述符与目标值来源	公开基准数据集；其原始来源（Materials Project、AFLOW、JARVIS 等）遵循各自条款。我们只使用其**数值型描述符表与目标列**，不做再分发以外的用途
实际使用（5 个）	`matbench_dielectric`（介电常数） `matbench_expt_gap`（实验带隙） `matbench_log_gvrh`（剪切模量） `matbench_log_kvrh`（体积模量，主扫描轴基底） `matbench_perovskites`（跨基底抽查）	主臂 5 个独立基底；消融臂复用其中 3 个（dielectric / expt_gap / log_gvrh）	同上
下载但未进入实验（2 个）	`matbench_glass`、`matbench_expt_is_metal`	**未产生任何结果**，仅随包分发	同上。如实列出，以免评审误以为我们用了全部 7 个子集

我们对数据做的处理（全部显式可复现，无一步依赖人工挑选）：

#	处理	为什么这样处理
1	只取数值型描述符（85 维元素分数 + `n_elements` + `z_mean` + `z_std` = 88 维），**不引入任何额外外部特征**	保证描述符完全来自原数据集，使「低维度失效」的结论不掺入我们的特征工程
2	候选池按固定规则抽样至 3000（种子固定），**不做任何针对目标值的挑选**	若按目标值排序后再抽样，等于把答案预先泄露给策略
3	命中标签 = 目标值 top-10% 分位，**由数据自身分位定义，非人为设定阈值**	使任何无偏策略的期望命中率恒为 0.100，可用 `random_uniform` 作口径自检探针（实测 0.100）
4	主实验臂在真实目标上叠加受控噪声构造可学习性梯度	**这是受控实验设计，不是伪造数据**：描述符空间、候选分布、成本结构三项保持真实；方法章与预注册 §10 均显式声明。凡涉及材料学解释的结论，只使用未降质的真实基底

> 补充一条操作如实记录：我们**没有**下载 matbench 原始结构文件做二次加工，官方 figshare / materialsproject 链接均返回 404/403，全部数据来自随包分发的 CSV 版本。这不影响任何实验（我们只需要描述符矩阵与目标列），但评审按 README 复现时会看到同样的 404，故提前说明。

2.2 模型与算法

组件	来源	说明
`RandomForestClassifier`（200 树）	scikit-learn（BSD-3-Clause）	仅用于计算「可学习性 AUC」这一**诊断指标**，不参与材料筛选本身
`GaussianProcessRegressor` + Matérn 核	scikit-learn（BSD-3-Clause）	贝叶斯优化的代理模型。我们做了三项**工程优化**（核参数热启动、每 20 步重拟合、候选子集采样），均为 BO 常规做法，不改变统计模型本身，且对所有 GP 策略一视同仁（预注册 §10 已登记）
UCB / EI 采集函数	自行实现（`strategies.py`）	非库函数调用
最远点（max-min）空间填充基线	自行实现（`strategies.py`）	替代被证伪的 LHS 基线，替换理由与证据见预注册 §10（这是本项目最严重的一次自我纠错：旧基线在 n=1 时分层结构消失，使测出的「BO 增益」实际在测「基线的运气」，全部旧结果作废并重跑）
大语言模型 / 外部 API	**作品运行时调用：零**	推理与决策**完全由确定性代码完成**，不联网、无随机网络依赖。这既是可复现性保证，也是设计主张（论证见 2.4）

2.3 代码与第三方库

类别	内容
自研代码（100%）	`agent_lab/` 下全部脚本，冻结包内 **5526 行 Python**（`wc -l` 口径，24 个 .py），连同包外复核脚本**共 6876 行 / 41 个 .py**：数据构建、实验主循环、四策略、成本模型、扫描轴构造、描述符消融、边界拟合、统计检验、准则卡与自我审计、Agent 决策闭环、端到端筛选、跨环境验证。无一行来自既有项目或他人仓库
第三方库	numpy、pandas、scipy、scikit-learn、matplotlib、statsmodels（均为宽松开源许可，BSD / PSF-style）
开发工具	Python 3.13；本地 + SciencePal 沙箱双环境执行，主循环统一到 `trial.py` 的 `run_trial()`（等价性由 `verify_trial.py` 逐点验证）

2.4 SciencePal 承担了哪一层

平台承担的是判断位的可审计性，不是算力。 三个判断实验（18 次盲态预测、1 次对抗审稿、双 Agent 对抗闭环）只能在平台上做，因为它们需要多 Agent 编排、逐次调用留痕、逐条判断可回放——这三项在本地没有对应物。本地能跑出 8640 个数字，跑不出「这个判断是哪一次调用做出的、当时看到了什么、事后被判对还是判错」。**计算可以搬走，判断的可审计性搬不走。**

平台能力	用在作品的哪个位置	换成本地会失去什么
多 Agent 编排	提议者 `d26e70b5` 判断、审计者 `ba26fa43` 终裁、否决权归确定性代码（技术报告 5.3.3）	两个角色必须在同一次会话里互相看见对方输出并留下先后顺序；本地脚本造不出「谁在什么时候看了什么」
逐次调用留痕	18 次盲态预测各挂一个 `run_id`，`results-extra/forecast_raw.jsonl` 可逐条回溯	本地日志只能证明「跑过」，不能证明「Agent 当时只看到了这些输入」——而防背答案的全部说服力就在这里
会话 Replay / 线程分享	作为「可运行作品链接」提交。Agent 页 `is_public` 服务端只读（PUT 返回 200 但静默忽略），匿名访客有两条入口：Replay 全程回放，以及把单个会话线程设为公开后得到的 `/share/{uuid}` 链接	评审将无法自行复核任何一条 Agent 判断
沙箱执行	独立复现验证:预算 200 档四组各 2160 run,与本地 8640 run 构成跨环境交叉验证（16/16 项一致,不含样本外）	换一台自己的机器也能跑，但「第二套硬件与库栈」不是自述，得由平台侧的真实环境给出

计算内核不依赖平台：`failbound_agent.py` 是纯确定性代码，零 LLM、零网络，任意 Python 环境可逐比特复跑，配置以 YAML 导出。这一点如实写——因为我们不打算用「平台依赖」冒充「平台贡献」。**平台贡献在另一处**：它让「Agent 的判断」第一次成为可以被复算、被回放、被判对错的实验对象；而这个位置上，此前是空的。

AI 编程助手是另一回事：开发过程中用它写代码、起草文档。这件事不用藏，但得说清它落在哪一层——它不参与实验执行、不生成任何结论，所以下面把系统切开，逐层注明由谁完成：

层	由谁完成	为什么必须这样分
交互层：理解研究者用自然语言描述的体系（候选池 / 目标性质 / 预算）→ 组成结构化诊断请求 → 把 AUC、边界、决策翻译回可执行建议	**LLM**（平台 Agent 形态）	这是 LLM 唯一不可替代之处：意图理解与解释。也是「Agent」相对「脚本」的价值所在
计算层：诊断 AUC、边界对照、USE_BO / 拒绝、反事实对照	**确定性代码**（`failbound_agent.py`，零 LLM 调用）	若让 LLM 参与这一步，8640 次 run 无法逐比特复现，证据链当场断裂，这正是本领域多数 Agent 不可审计的根因
审计层：错误率（漏报 0/27、误杀 5/9）、校准数字（773 / 780 / 833 / 539）	**确定性代码自动生成**	自我评估不能由被评估者自己撰写，否则「诚实」只是一种文风

运行时零 LLM 调用(指测量回路内;判断实验见技术报告 §5.3)是算过的结果,不是省事。标定工作要回答的第一个问题是「同一个体系、同一个预算，换一次运行结论会不会变」，执行链里只要嵌进 LLM，每次 run 都带上不可复现的随机性，这个问题就没法回答。所以 LLM 被**移出测量回路**，只留在回路之外的接口层：模型在接口上说话，闭环里每一步由代码执行，再由代码质疑上一步。

所有科学判断（问题定义、实验设计、假设、统计口径、结论解释）由参赛者本人做出并负责。

2.5 外部文献的使用（2026-10-21 补充）

技术报告 §1.5 引用了 10 项他人公开发表的工作（Lowell 2019、Karamcheti 2021、Rohr 2020、Tamura 2024、Cinquin 2025、Dastin-van Rijn 2025、Wang 2016、Liang 2021、Riebesell 2025、Panickssery 2024）。使用方式仅限三种：① **定位**——说明"AL 会输给随机"已被证明，本文不再重复；② **对照**——特别是 Tamura et al.（Sci. Rep. 2024）与本文轴 B 方向相反，我们为此补了同维对照（技术报告 §3.3.1）而不是回避；③ **方法依据**——如边界规避核、有效维度 d_e 的措辞。

三条界线：**不参与任何计算**（所有数字来自本地 8640 次 run 与 `results/`）；**不构成赛前成果**（公开文献，非团队成果）；**文献检索发生在 2026-10-21**，晚于全部实验与预注册，其作用是修正措辞、补一项事后检验，**没有改动任何预注册假设或既有数字**（偏离登记见技术报告 §2.3）。

2.6 两项事后自我修正（2026-10-23）

这两项都**没有产生任何新数据**，也**没有改动任何实验数字**；它们改的是本文对自己的表述，方向都是往下调：

1. **统计口径降级。** 复核发现 §3.5 的 p 值按任务计自由度，而 18 个任务实际只来自 3–5 个物理体系（`__lam*` 是同一体系的目标降质档位，`__pca*`/`__rp*`/`__elem20` 是同一体系的特征表示）。把重抽单位从任务改为体系重算（`cluster_robust.py`），主臂体系级 95% CI 变成 **[−0.875, +0.952]**——**原 p=3.9e-6 不再成立。**因此本文把**所有单臂 ρ 的 p 值降级为描述性陈述**，改用两条抗簇结构的证据：5 个体系内部 ρ 全为正（+0.601/+0.678/+0.853/+0.944/+1.000，5/5 同号，p=0.031），以及 51 个任务合并后的体系级 CI [+0.422, +0.861]（p=0.0004）。这条修正**缩小**了本文可主张的范围。
2. **对核心解释的否定。** `repr_effect.py` 显示主臂 18 个任务里 12 个是同一物理体系的 12 档目标降质 λ，且该段增益跨度达 18.8 倍而描述符维度恒为 85；消融臂 3 体系 × 6 表示的完整交叉给出体系只解释 **1.9%–4.4%** 方差、表示占 **74%–81%**（单策略 gp-UCB/EI 口径；三因素合并口径为 41.1%）。这推翻了原先「体系的可学习性预报增益」的说法，改为「**预处理强度同时抬高了 AUC 与增益**」。这条同样**否定**了本文自己的主结论方向（技术报告 §3.5.1）。

两项均已在预注册文档的偏离登记中登记（S8），并**主动公开**在说明与技术报告正文里，而非藏进附录。

三、赛前已有成果 vs 赛事期间新增（切割表）

维度	赛前已有（2026-10-15 之前）	赛事期间新增（本作品全部内容）
科学问题	无	「主动学习何时不该用」的失效边界标定，本作品首次提出并操作化
实验设计	无	受控降质扫描轴（12 档 λ × 3 基底）、描述符消融臂（3 族算子 × 3 基底）、预注册文档（含 39 条偏离登记）
代码	无（未复用任何旧项目代码）	`agent_lab/` 全部脚本，5526 行（24 个 .py）
数据产物	无	4 个实验组 × 18 任务 × 4 策略 × 30 种子 = **8640 次完整 run**，逐 run 落盘为 jsonl 轨迹；另有 Agent 决策日志与端到端筛选候选清单
结论	无	主臂 **18/18 显著为正且未拟合出零点**（`AUC*=None`，即该轴范围内 BO 始终不劣于随机）；消融臂存在 **−33.9** 的灾难性失效，零点 **AUC*=0.731**、CI [0.556, 0.807]；跨轴差异检验 **p=0.052（未达 α=0.05）**；**Agent 累计命中 773 < 无脑全用 BO 的 780**（负结果，如实报告）
个人背景（无人机方向工程经验与既有论文）	存在	**与本作品零重叠**：不同问题域、不同代码库、不同数据集、不同结论。本作品未引用、未复用、未受益于这些材料

左列全空，本作品的内容都在右列。

四、声明 → 证据对照（每行都可点验）

原创性声明的通病是「自证」：声明越完整，越无法验证。所以这里把每条关键声明指向一个具体产物，评审可任取一行抽查。

#	声明	可点验的产物	怎么查
1	代码为本作品新写	`agent_lab/*.py`（24 个脚本 / 5526 行）	任取一个脚本通读，`agent_lab/README.md` 给出逐模块职责；无任何外部仓库的业务代码
2	主实验确实跑完、无缺片	`results/runs_{nogate,gate}[_ablate].jsonl`	每个文件恒为 2179 行 = 1 meta + 2160 run + 18 task_meta；`merge_shards.py` 做完整性自检，缺片直接报警
3	数字不是手抄的	`results/*.csv`、`results/boundary_fit.json`	跑 `analyze.py` 与任一提交文档逐项比对。文档数字自检有两个版本：包内 `agent_lab/check_report_consistency.py`（冻结版，**22 项**，评审解包即可直接运行，通过）与包外 `check_report_consistency_v2.py`（作者侧超集，**55 项 + 4 个作废值黑名单**）
4	分析口径事先写死	`preregistration.md`（§10 共 **39 条**偏离登记）	逐条读：每一条都写了「改什么、为什么改、对结论的**方向**是有利还是不利」
5	核心循环重构前后结果不变	`verify_trial.py`	6 组配置 × 3 种实现，重构前后 chosen 序列 sha256 逐点一致，退出码 0
6	沙箱真的执行过这批代码	`results/sandbox_claims.json` + `verify_sandbox_claims.py`	五层验证:**冻结 zip 与沙箱所跑包 101/101 文件 SHA256 逐比特相同**（L1/L2）、任务参数 26/26 观测点一致（L3）、文件结构一致（L4）、行为指纹对齐（L5）
7	没有偷偷用 LLM 补数字	`failbound_agent.py`、`run_experiments.py`	全文检索无任何 `openai` / `requests` / `http` 调用；断网可完整复跑
8	没有把失败藏起来	技术报告 3.6「三处弱点」、4.4「准则卡自我审计」	负结果写在正文与摘要，不只在附录：−33.9 灾难、773<780、漏报 0/27 与误杀 5/9 都在正文

> 第 3 行那两个版本要单独说明，它暴露了一个典型陷阱。包内那份脚本一旦改动,L1 就会从 101/101 掉成「可执行代码 85 项不一致」。

---为了让文档多核对十几个数字，反而亲手毁掉一条比它强得多的密码学级证据。所以正确处理是：包内保持冻结不动，升级版放包外。顺带修掉了旧版两个更隐蔽的问题：旧版只做「数字必须出现」的存在性检查，旧值留在文档里也不报警，曾导致两份文档给出相反结论；还用一个 `except: pass` 包住取数，在没装 pandas 的解释器上核对数会从 36 悄悄掉到 18，却仍打印「全部一致」。**一个会静默降级的检查脚本给出的绿灯，比红灯更危险。**v2 现在缺依赖即非零退出。

五、团队分工（单人参赛）

角色	承担人	内容
科学问题定义与实验设计	本人	全部
代码实现	本人（AI 编程助手辅助）	全部
实验执行与数据核验	本人	全部；本地 8640 run + SciencePal 沙箱 8640 run 双环境交叉验证
统计分析与结论	本人	全部
文档与提交材料	本人（AI 编程助手辅助起草）	全部

分工是这样的：**人决定问什么、信什么，代码负责算出来、记下来。**

六、合规与可复现

1. **无人类受试者**、无敏感个人信息、无动物实验，全部为公开材料数据集上的计算方法研究。
2. **不宣称发现新材料**：本作品产出的是「方法与边界」；端到端筛选 demo 给出的候选清单是**方法演示**（报告的是富集倍数 2.2–3.4×（命中率 0.218–0.341 对随机 0.100）与化学可行性标记），未经验证，不作为材料发现成果。**另有一条我们主动披露的检查失效**：化学可行性检查依赖「85 维元素分数」反推组成，而消融任务的描述符已被投影，这个前提不成立（实测出现过 `K105%` 这类超过 100% 的组成），故消融任务上的候选清单**不宣称任何化学可用性**；该检查只在 3 个真实锚点上有效。
3. **可复现**：主种子 `SEED = 20261015` 固定，子种子由 blake2b 派生（跨机器稳定）；所有 run 落盘为 jsonl 轨迹。复现路径与耗时：

步	命令	产出
1	`python run_experiments.py no-gate 30 --max-budget 200 --proc 4`	实验轨迹
2	`python analyze.py both`	统计、图、边界拟合、准则卡
3	`python screening_demo.py --budget 200 --seeds 10`	端到端筛选候选清单
4	`python verify_sandbox_claims.py`	跨环境五层验证（退出码 0）
5	`python check_report_consistency.py`	文档数字自检（包内冻结版，22 项；包外升级版 `_v2` 覆盖 55 项 + 4 个作废值）

4. **负面结果已如实报告。**这一条需要精确表述，因为它最容易在转述中失真：

- 自研 Agent 的实测表现**低于**无脑全用 BO（773 < 780），且这写在正文而非附录；
- 「两条轴的后果不同」这个核心对比，**直接检验 p=0.052，未达 α=0.05**，故全文措辞按「方向一致的差异趋势」处理；
- 在三个候选的单值判据中，**只有「可学习性分离度」达到显著但偏弱**（Spearman ρ=0.513，p=0.030，任务级），另两个不成立（维度 ρ=0.452 / p=0.060 边缘，基底命中率 ρ=−0.289 / p=0.246）；即便如此，它的强度**不足以支撑一个自动开关**，准则卡因此被设计成保守熔断器而非自动决策器。

> 这一条曾是本声明自身的缺陷：早期版本写作「三个候选判据 p 值均 > 0.10」，与 `results/predictor_strength.csv` 的真值相反（AUC 判据其实是显著的）。该错误已修正，并已把 4 个作废值写入自检脚本黑名单，防止旧文案回流。**我们把这次自我纠错留在文档里，而不是悄悄改掉。**

七、三处我们必须自己指出的限定

#	限定	量化	影响
1	**受控降质不是真实材料**	主实验臂通过给真实目标叠加噪声构造可学习性梯度	描述符、候选分布、成本结构保持真实，但**目标值是受控改造过的。**因此凡涉及材料学解释的结论，只用未降质的 3 个真实基底
2	**有效样本量小于名义样本量**	名义 36 个任务，去重后只有 **5 个独立基底**（log_kvrh / perovskites / dielectric / expt_gap / log_gvrh；消融臂复用的就是主臂其中 3 个，不可重计）；主臂 18 个「显著为正」里 15 个来自两个基底的参数扫描	跨任务统计的自由度应按 **5** 而非 36 理解，全文已按此标注；18/18 的显著性不可外推到真实独立任务
3	**边界位置本身随基底移动**	留一基底重拟合：全样本 **0.731**；去掉 `dielectric` 后 **0.578**、去掉 `expt_gap` 后 **0.805**、去掉 `log_gvrh` 后 **0.720**。以基底为单位的聚类 bootstrap（1000 次）95% CI **[0.564, 0.830]**，仅 **66.2%** 落在 0.70 以上、**11.9%** 掉到 0.60 以下	「0.731」**不是物理常数**，只是这三个基底下的经验位置。故对外只能表述为「低可学习性区 BO 会变差、零点大致在 0.73 附近」，**不能说**「0.731 是一条精确阈值」

第 3 条是本轮新增的：只承认「样本量小」是不够的，必须回答「那结论还站得住吗」。测量结论是：方向站得住，精度站不住。所以我们主动把阈值降级成区间。

八、逐条对照提交要求

要求	本文件对应位置
原创性声明	全文；核心为一、三、四节
赛前 / 赛中切割	第三节
数据与资源许可	2.1、2.2、2.3
第三方代码与库声明	2.3（列明库与许可类型；无一行外部业务代码）
AI 使用披露	2.4（含三层分工表与人机边界）
团队分工	第五节
合规与伦理	第六节第 1–2 条
可复现性	第六节第 3 条（5 步命令 + 固定种子）；第四节第 5–6 行（逐比特验证）
负面结果披露	第六节第 4 条、第七节