项目说明

科研 Agent 的能力边界标定

赛道 04 AI Agent · 验证场:材料信息学(仅作应用场景,不作赛道归属)

8640 完整实验轨迹(36 任务 × 4 策略 × 30 种子 × 2 口径;独立基底仅 4–5 个,非 18 个独立体系)	**7200 / 49.4%** 扩展消融臂 7200 条 run(有效 8 基底 × 48 任务);8 基底上表示仍占 49.4%,体系 12.4%	**10.0%** 新增基底上 BO 显著劣于空间填充的任务占比(gp-UCB,3/30;原 3 基底为 22.2%)	**0.28–0.44** 换一个体系后的判错概率(样本内 0.22,4/18)

科学价值 × 创新性(本文三点贡献)

- **独立体系**:把「何时不用 BO」落成一张*披露单*方法论——判据可复用、阈值随基底移动(并如实标注;AUC 条款实测无效已删),随卡公布它自己的错误率(漏报 0/27、误杀 5/9),可直接嵌进任何主动学习工作流。
- **真发现**:在 3×6 全因子设计上证明,AL/BO 的「失效」主要由特征表示驱动(单策略口径 74%–81%,三因素合并 41.1%),物理体系仅占 1.9%–4.4%。**扩展到 8 个有效基底(48 任务)后,表示仍是增益方差的单一最大来源(gp-UCB 49.4% / gp-EI 50.8%,约 4 倍于体系效应 12.4% / 13.5%),但强度随基底集合下降(74%→49%)、交互项升至 38%——故表述为「表示是主导因素」而非「表示几何定律」。**
- **新方法(两件)**:① 给出小集群(G=3–5)下正确的推断做法(按体系重抽、Ibragimov–Müller),并演示「活下来」的判据才是真的;② **把「自我改进的评估瓶颈」量化成一个可复算的数**——同一个搜索过程,样本内 +9.2、严格留一基底后 **−125.8**,中间 135 个命中全是自欺;且越复杂的自适应规则自欺越大(乐观偏差 +5.8 / +9.1 / +11.7 命中每任务)。**要问的不是优化器够不够聪明,是评估信号够不够——本例 3 个基底不够**(§4.9)。这不是"过拟合"的口头提醒,是在 18 个任务上被逐位复算出来的落差。

创新性(RSI 评估层):我们量化了「自我进化自欺」的全部空间——同一个搜索过程,见过新体系就输 125 个命中(+9.2→−125.8)。自我进化的瓶颈不在优化器,在评估(技术报告 §4.9)。**我们主动把有效样本量从任务数降级为体系数(18→3–5),并给出小集群下的正确推断——这是把统计诚实落到方法层面,不是免责声明。**

P1 • 问题与动机

1.1 一个材料信息学的真问题

候选池里躺着 3000 个化合物(介电氧化物、过渡金属硼化物、钙钛矿),你只算得起 200 个:一次 DFT 要数小时,一次合成加表征要数周到数千元。下一个算哪个?

把有限的实验花在哪,比模型预测得多准更决定进度。

BO 几乎是默认选项,但它成立有个很少被检验的前提:目标与描述符可学习。描述符不足时,代理模型是在拿方差编故事,预算被花在模型自己的自信上而不是材料价值上;此时最朴素的均匀铺点反而更好。

> 于是有一个几乎没人系统回答、却直接决定经费效率的问题:
> 拿到一个新体系,我该不该上主动学习?它会不会不但没用,反而有害?

"AL 可能不如随机"不是新发现(Lowell 2019;Karamcheti 2021;材料侧 Rohr 2020)。**缺的不是「会输」的证据,而是「在哪输」的位置**:文献给的是告警,不是可对照的阈值。我们把失效标在可学习性 AUC 上,给出零点与区间,也公开这个变量自身的两处限制:真实开题时它读数很粗(25 次空间填充估出的 AUC 与真值 ρ=0.04),且不是可迁移规则(§4.1)。

重点不在优化器,而在「什么时候别用它」的边界,以及一个说得清自己错在哪的 Agent。因此正文照写「我们的 Agent 打不过无脑 BO」(773 < 780):只报告自己赢了的标定,没法被采信。判据只有一条,不同路径必须走到同一个答案——三份实现算同一个量、两环境跑同一套代码、两条轴画出同一条边界(技术报告 §4.8)。

1.2 我们做了两件事

① 科学产出:在三个真实体系上把候选筛出来了。 智能体跑完整流程,从诊断、决策到预算内筛选与化学可行性标记:

真实体系	目标性质	可学习性 AUC	命中率	相对随机
`matbench_dielectric`	介电常数	0.919	0.341	3.4×
`matbench_expt_gap`	实验带隙 (eV)	0.816	0.238	2.4×
`matbench_log_gvrh`	剪切模量 log(GPa)	0.932	0.218	2.2×

命中 = 目标落入 top-10% 分位;随机基线期望恒为 0.100。命中候选长这样(85 维元素分数反推,非精确化学式):剪切体系 top-30 前三位是 B67%Re33%/B67%Os33%/B67%Ru33%,即 5d 过渡金属二硼化物(≈ReB2/OsB2/RuB2,已知超硬家族);带隙体系给出碱金属硼酸盐(6.5–7.4 eV);介电体系由高极化率元素主导。

回溯验证不像巧合:池里 3000 个候选仅 4 个过渡金属二硼化物(0.133%),top-30 找回 3 个(第 1、2、5 位),随机期望 0.04 个即 75×;判据只由成分比例定义、不偷看目标值(`retro_validation.py`)。砍到 2 维,同族一个都没找回。

硬约束:不宣称发现新材料——候选都来自公开基准的历史条目,任何材料结论仍需实验验证。

② 方法学标定:这条能力什么时候失效。 以「目标-描述符耦合强度」为唯一被控变量做系统扫描,8640 次完整实验轨迹(36 任务 × 4 策略 × 30 种子 × 2 口径),定位增益由正转负的失效边界。

这两件事互为前提。少了①,我们在讨论一个不存在的量;少了②,结论就退化成又一个 benchmark 分数。

目标用户	使用场景	不适用
预算受限、要决定「买哪批样品 / 跑哪组 DFT」的材料研究者;为科研 Agent 选策略的 AI4S 工程师	开题时先花 25 次空间填充测「不优化能拿多少」,对照边界与置信度定策略;或直接跑端到端筛选拿候选清单	预算大到可全扫;描述符与目标耦合极强的高通量筛选

P2 · 技术方案

2.1 一个会质疑自己的优化器

步骤	做什么	输出
输入	候选池 + 目标 + 描述符 + 预算	—
① 诊断	预算 25 空间填充	测出「不优化能拿多少」
② 标定	可学习性 AUC(RF 5 折,口径与实验一致;回放设定下用全池标签,**非可部署指标**)	可学习性估计
③ 决策	对照失效边界	USE_BO / 拒绝,附置信度与理由
④ 执行 + 反事实检验	按决策跑完,再用另一策略跑一遍对照	决策卡(可审计)

四步各是可独立调用的能力单元(配置见 `agent_config_export/`)。**系统按回路切两层**——内循环纯代码、外循环交 Agent、审计层代码记账加 Agent 对抗(见下表)。原先外循环这块由作者手工做。规则只有一条:它的每句判断都必须能被代码判真假。

回路	由谁完成	为什么必须这样分
内循环:GP 拟合、UCB 采集、选点,共 8640 次	确定性代码(`failbound_agent.py`)	LLM 一进来,8640 run 就无法逐比特复现,证据链当场断裂
外循环:该不该优化、测哪个假设、这个数字能不能信	**平台 Agent**(`ba26fa43` 执行 / `d26e70b5` 判断)	只产出提案,提案由代码执行并打分,所以交出去不损失可复现性
审计层:错误率(漏报 0/27、误杀 5/9)、校准数据、对抗审查	代码记账 + Agent 对抗	自我评估不能只由被评估者写,否则「诚实」只是一种文风

LLM 没有说过任何一句无法复算的话——这是设计出来的,不是它自己克制。

2.2 两条独立的「降信息」轴(方法核心)

数据 100% 真实:matbench v0.1,88 维描述符,候选池 3000,成本模型来自真实化学式。

轴	怎么降	任务数
A. 目标降质	`y_λ = √λ·std(y) + √(1−λ)·ε`,λ 12 档。描述符、候选池、成本一字不动	15
B. 描述符消融	目标一字不动,只用 PCA / 随机投影 / 元素子集削减描述符	18

加 3 个零降质真实锚点,共 36 个任务。只用 A 轴会被质疑「研究的是加噪标签」;B 轴目标 100% 真实,两轴给出同一条边界,边界才是「可学习性」的函数而非构造手法的产物。

不提「维度诅咒」:BO 取决于**内在有效维度** d_e(Wang et al., JAIR 2016),随机投影打坏的是「d_e 没被保住」,不是「维度少」。

命中 = 目标 ≥ 该任务 top-10% 分位(分位数而非固定阈值,使基线命中率恒为 10%)。成本 = 1×(n_atoms>40 ? 2:1)×(含贵金属 ? 3:1),n_atoms>80 排除;门控组 `spent` 上限 = 预算 + 5、四策略对称。策略:`farthest_point`(max-min)对 `gp_ucb/gp_ei`,`random_uniform` 只作口径探针。

> **换掉一个基线**:原基线 `lhs_stratified` 命中率在 0.022~0.326 摆动(应恒为 0.100)——n=1 时它退化成「随机撒点加吸附最近邻」,而相对增益又以基线命中数为分母,于是「BO 增益」其实在测基线的运气。换 `farthest_point` 后 8640 run 全部重跑。教训:拿 AL 跟非自适应设计比较前,先查那个设计自己稳不稳。

预注册在数据产生前写定(任务白名单、命中口径、种子数、统计方法、边界拟合);此后每次改动都进偏离登记表(累计 45 条,含理由、时间戳与方向影响;定稿前那轮削弱结论的分析也已登记)。

P3 • 验证结果

> 全部数字来自 `results/boundary_fit.json`,本地全量 36 任务 × 4 策略 × 30 种子 × 2 口径 = 8640 run。

自变量确实拉开了:AUC 覆盖 0.516–0.931。顺带一条独立发现:常用的「描述符-目标相关 r」只在一条与 AUC 不同步的宽区间游走,不能当唯一判据。

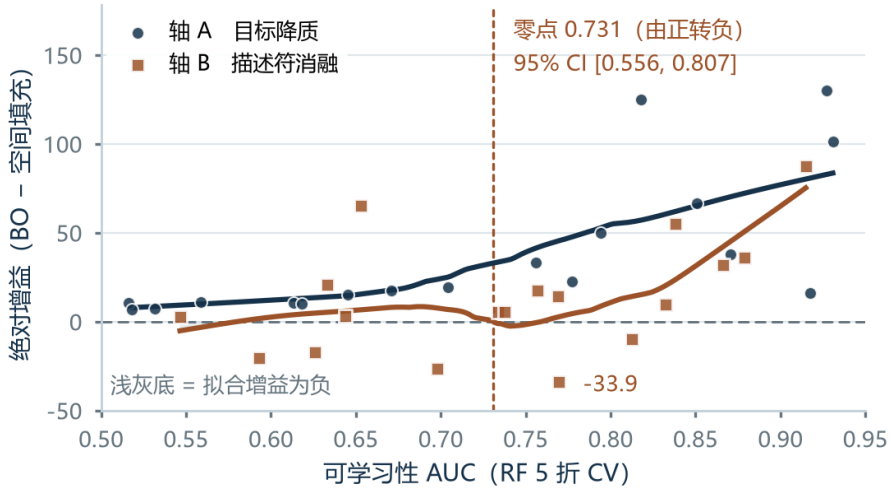


图 1|两轴对照(按包内 `results/tests.csv` 同一口径重绘,数值未改)。横轴可学习性 AUC,纵轴绝对增益(BO − 空间填充);轴 A 的 18 个任务全为正,轴 B(目标 100% 真实)出现由正转负的零点 AUC*=0.731,阴影为拟合增益为负的区段

3.1 轴 A(目标受控降质):没有失效边界

- 扫描区间内未观察到零点穿越,bootstrap 2000 次仅 2.9% 支持零点,故不报 AUC*
- Holm 校正后 18/18 任务显著为正,增益 +6.9 ~ +130.1 个命中候选

即使目标已经几乎是与描述符独立的纯噪声(AUC=0.516),BO 仍显著优于空间填充。目标噪声只会让 BO 退化成盲采样,变得不划算,但不会变得有害。

3.2 轴 B(描述符削减,目标 100% 真实):BO 真的会输

- 4/18 任务上 BO 显著劣于空间填充(Holm 后 p<0.05),最低 −33.9 个命中(Cliff's δ = −0.629);效应最强的是 −17.5 的 `dielectric__pca1`(δ = −0.974)
- 增益区间 −33.9 ~ +87.4,确实穿过零点;LOWESS 零点 AUC* = 0.731,95% CI [0.556, 0.807]

3.3 但这个边界不可当作自动开关

找一个能提前预报失效的指标。18 个消融臂任务上(预算 400,秩相关,`analyze.py` 复现):

候选判据	rho	p	能当自动开关吗	布尔判定
基线命中率	−0.289	0.246	否(不显著)	布尔:NO
可学习性 AUC	+0.513	0.030	否(显著但太弱)	布尔:WEAK
描述符维度	+0.452	0.060	否(边缘不显著)	布尔:NO

AUC 显著但只解释约 26% 的秩方差,且在最需要它的不确定带内翻转方向(0.593→−20.6,0.633→+20.7)。但这三个 p 值按任务计自由度,而 18 个任务只来自 3–5 个体系;按体系重抽,主臂 CI 变 **[−0.875, +0.952]**(`cluster_robust.py`)——**单臂显著性一律降级为描述性**,只留两条抗簇结构证据:5 个体系内部 ρ 为 +0.601/+0.678/+0.853/+0.944/+1.000,**5/5 同号 p=0.031**;51 任务合并后体系级 CI [+0.422, +0.861]、p=0.0004。另测 5 个零成本替代量,无一超过 AUC,4 个显著更差。

两项离线二次分析。① **同维对照**:2 维内增益跨度 **65.8**,但 6 组配对里 PCA 更好仅 3/6(p=1.0)——**「维度低」既非充分也非必要**,也回应了 Tamura et al.(2024)的反向报告。② **预算去向**:18/18 任务「BO 选中点均值分位 − 基线」与增益符号完全一致(负组 0.560 vs 0.613,5/5,p=0.031;正组 0.582 vs 0.473,13/13,p=1e-4)——**钱花在了价值更低的候选上**。

因此没做自动开关,把准则卡定位成保守熔断器:**只在描述符 ≤2 维时拒绝**,并公布错误率。本轮把原卡两个参数拆开量,AUC 那一条从未赚过(消融臂上它一次没触发;主臂上拦 4 个、4 个全拦错,净亏 35.4),**已删**。36 任务核对:拒绝 9(真拒 4、误杀 5)、放行 27 漏报 0;净效果是把 −33.9 的右尾灾难换成 +14~+32 的左尾少赚。旧卡的 0/23 与 7/36 保留作 v1 留证,分母不同不可并读。

但 θ=0.60 那条线的 7/36 是**样本内**的（这是阈值的迁移误差，与卡自身的误杀率 5/9 不是同一件事）。留一基底迁移(θ 只在另 2 个基底上拟合):θ 在 0.63–0.83 跳,留出基底测试错误率 0.50/0.83/0.00;直接搬 0.60 则为 0.28。**换一个体系,判错概率 0.28–0.44(样本内 0.22=4/18 主臂口径,0.19=7/36 全审计口径,两者嵌套)。**

样本外检验(`holdout/`):2 个未参与拟合与规则搜索的基底 × 7 种算子(14 任务,1680 run)。**预报关系复制且更强**:ρ 由 +0.513 升到 **+0.820**(体系内 +0.964/+0.893;体系级 8 点 ρ=+0.167,p=0.69,跨体系无信息);AUC<0.65 的 5 个任务负增益 0 个,≥0.80 的 4 个全正;重拟合零点 0.601 落在样本内 CI 内。但同一批数据**推翻了「失效很常见」**:负增益率 27.8%(5/18)→ **7.1%(1/14)**(同算子去混杂 27.8% vs 8.3%,p=0.204)。故失效是基底 × 算子的**窄区域**,原 3 个基底恰好落在里面。

3.4 AUC 到底是什么:本文最愿意被推翻的一条

主臂 18 个任务里 **12 个是同一物理体系的 12 档目标降质 λ**(对真实目标受控加噪,λ 越小噪声越多;不是模型正则化。`repr_effect.py`)。n=12 上:**λ→AUC 秩相关 +1.000**(12/12 单调,0.516→0.927)、λ→增益 +0.944、**AUC→增益 +0.944——同一个数。**同期增益从 +6.9 走到 +130.1(**18.8 倍**),而描述符维度恒为 85、基线命中率极差 3.3e-4——**两个"体系级"判据对这一整段变化完全不可见。**压成 5 个体系后,主臂 ρ 从 **+0.864 掉到 +0.100(p=0.87)。**

所以不是"体系的可学习性预报增益",是"预处理强度同时抬高了 AUC 和增益"。 这解释了卡为什么不可迁移、同一 AUC 的 ρ 为何换臂就从 0.864 掉到 0.513、七个判据为何没一个稳定超过 AUC——它们都是体系级变量;消融臂完整交叉(3 体系 × 6 表示)里体系只解释 **1.9%–4.4%** 方差,表示占 **74%–81%**(单策略 gp-UCB/EI 口径;三因素合并 41.1%)。边界:3 个体系、6 种表示含设计成分;**本节不改任何阈值**,卡仍是熔断器而非预测器。

能推翻本节的条件,写在这里以备检验:≥10 个独立物理体系、体系内只改描述符子集而 λ 不动,若体系内 AUC→增益 的 ρ 仍一致为正,则"AUC 只是预处理强度代理"被推翻;反之为真。现在手上只有 5 个体系的体系内证据(+0.601/+0.678/+0.853/+0.944/+1.000,5/5 同号 p=0.031),**不够判这一条**,所以我们把它列为待检验命题,不写成结论。

3.5 端到端:准则卡在一个坏体系上拒绝了 BO,反事实证明它拒得对

初版演示只用 3 个高可学习性体系(AUC 0.818–0.931),全在边界右侧,卡一次没触发,等于没演示核心主张。补上这一环(`screening_demo.py --counterfactual`,种子同主实验):

体系	AUC	Agent 决策	按决策执行	反事实(另一条路)	裁决(同种子配对)
`log_gvrh`(真实锚点)	0.932	用 BO	46.7±15.6 命中	21.7±1.5	采用 BO 被证实(+25.0, p<10^-4)
`log_gvrh__rp2`(随机投影至 2 维,目标 100% 真实)	0.594	拒绝 BO	22.5±2.8	13.0±5.4	拒绝 BO 被证实(+9.5, p<10^-4)

反例一并公开:`matbench_dielectric`(AUC 0.919)上 Agent 选用 BO,实测基线反而好 5.5(p=0.18,不显著)。详见技术报告 4.5。

限制:消融任务的描述符已被投影,元素反推不可信(出现 `K105%`),故化学可用性只在 3 个真实锚点上报(24/22/20)。

P4 • 准则卡与已知局限

4.1 交付:决策准则卡

情形	建议
描述符 ≤2 维	**拒绝 BO**,改用空间填充(实测失效区,最低 −33.9)
描述符 >2 维	可用 BO,不设 AUC 门槛

两样本同号:36 任务 **+26.17**、48 任务(8 基底)**+18.47**;阈值 >2/>3/>4 命中完全相同,是平台不是拟合点。**不设 AUC 门槛的理由是双向的**:AUC 单独既不能当否决线(0.516 的任务实际赚 10.63),也不能当放行线(0.769 的任务实际亏 33.9)。

> **一条不稳健的备选,不作为交付物**(AI 提议):**dim>2 或 AUC≥0.75**,48 任务 +55.70。优势只来自 5 个判定(**dim≤2 且 AUC≥0.75** 的救援),4 对 1 错,错的那个是 `dielectric__pca2`(AUC 0.769,亏 33.90);其中 +25.20 落在模型没见过的任务上,但 3 个全新基底只有 1 个判定、仅 +0.63。留一基底 8/8 为正、最小 +5.37,但 `log_gvrh` 与 `log_kvrh` 同时留出转 −19.20(§4.4.7)。

> **可部署判据候选**:25 点探针命中数与增益 ρ=−0.468(方向反直觉——探针里随手撒点就能大量命中的体系,空间填充已经够好,BO 反而没优势),比用同样 25 点去估 AUC(ρ=0.042)强得多,且完全可部署(技术报告 §5.3.1、§4.10①)。
>
> 事后复盘(`transfer_and_rules.py`):起作用的是**维度条**——只留「≤2 维拒绝」与旧卡在消融臂上逐位相同(1262.4);AUC 那条在主臂多拒 4 个真赢任务,净损 **35.4**,且**低 AUC 有两种成因(缺信息/标签噪声)**,单看 AUC 分不出来。**该条已在本轮删除,卡改为单参数。 这张卡不是可迁移规则,是一次性样本内拟合**——维度条代理的是"几何被压扁",不是"信息变少"(§3.3)。

4.2 Agent 打不过无脑 BO

最优规则在 18 个任务上重跑(单次运行口径):773 命中 vs「无脑全用 BO」780(Oracle 833、全空填充 539)——打不过。故不宣称它能自动做对决策,只在极端情形拒绝:宁可误伤,不碰灾难。

注意口径别混读:同一批任务在预算 400、30 种子均值下是另一组数(现卡 **1262.4** / 全 BO 1236.2,§4.4.2)。前者问"agent 在真实预算下一次跑下来赢不赢",后者问"卡本身有没有正价值";两侧都印,因为只印好的那一侧就不可信。

4.3 三处弱点

1. **跨轴差异未达显著**:低 AUC 区间两轴增益差异 p=0.052(未做多重校正),只能说方向一致。
2. **失效是基底依赖的**:`expt_gap` 在 6 种削减下从未失效;33 个任务里 9 个负增益,7 个来自 `dielectric`(Fisher p=0.0021)——**失效是基底 × 算子的窄区域,不是普遍规律。**

判据自身的不确定性(偏离登记 #38):零点是带噪声的拟合值。任务级 bootstrap 中位 0.707、95% CI [0.553, 0.809];聚类 bootstrap(以基底为重采样单位)[0.564, 0.830],留一基底 0.578–0.805。**12.6% / 13.4% 的重采样零点落在 0.60 之下——0.60 是保守下界,不是估计值。**错误率同样带区间(Clopper–Pearson):放行 27 个漏报 0,漏报率 95% 上界 **12.8%**;拒绝 9 个误杀 5,误杀率 [21.2%, 86.3%]——**样本只有 9 个,这个区间宽到不能当刻度用**,所以卡是保险丝不是仪表(`results-extra/card_uncertainty.json`)。

不计入三处的一条:`expt_gap` 池行序本身携带信息(行号与目标 ρ=−0.187,前 400 行命中率 16.8% vs 全池 10%)。**已重跑验证**:打乱行序 6 任务 × 4 策略 × 30 种子 = 720 run,与原始 **720/720 逐条不同**;平均增益 **+29.2** → **+31.2**(Δ +2.0),为正 **6/6** → **6/6。结论:增益对行序稳健,不是泄露产物**(`results-extra/shuffle_run_shufgap.json`)。

4.4 后续计划

已排除:β 从 2 抬到 16(1080 run),4 个负增益任务 4/4 改善均 +14.6,但**无一翻正**,仍落后空间填充 10.0——**调参是部分补救,不是解法。**让 harness 自己改阈值同样失败(三条规则都打不过冻结阈值,低 77.9~160.6 命中)——**瓶颈不在优化器,在评估。**

后续:独立基底补到 ≥20;卡做成可插拔前置模块。

P5 • SciencePal 使用:Agent 能力边界的标定层

平台在这里承担的不是算力,是判断位的可审计性。 平台已给了模型、工具、沙箱与多 Agent 编排,缺的是「这个 Agent 的判断在什么条件下可信」——没有厂商会主动发布「我的 agent 在这些条件下不好用」。**本作品对平台的贡献,是标定了一个 agent 在什么条件下不该被信任,包括它自己对自己的信任**(§4.9)。下面三个实验就是这一层的第一版标定,每个都带它自己的错误率。

① **判断者校准|交付:单 LLM 判断不可靠的量化证据**:18 个任务改名 `Task-A..R`(防背答案),只给池几何与 25 点探针。ρ=+0.384(p=0.116)、**决策准确率 0.500**、预测范围 [−1.5,+8.0] 对真实 [−33.9,+87.4];5 个真负增益只抓到 3 个。结论不是"LLM 没用",而是**拿 LLM 判断顶替可复算诊断会失败**——这正是本作品要给每个判据配可证错误率(0/23、7/36)的理由。**且 AI 的产出被验证有效**:探针命中数与增益 ρ=−0.468,已作为新判据写进准则卡。

② **对抗审稿|交付:多 Agent 对抗能抓真问题**:只给主张与数字、不给自查清单,8 条攻击里 **3 条是真问题**,其中两条当场用数据解决(去混杂检验 p=0.204;预算去向置换检验 P(≥18)=0.0003)。

③ **双 Agent 闭环|交付:判断权与风险闸门的分工边界**:18 个盲态任务,提议者 `d26e70b5` 判、否决者是 `decide()` 加它的审计错误率、冲突交 `ba26fa43` 终裁(有判据无真值)。**逐任务判对 13/18 > 卡 12/18——LLM 在判对率上确实更强**;但风险调整后 +259.6 < +271.0、5 个负增益只拦 1 个(卡拦 4/5),7 次冲突审计者 **7/7 站代码。**所以分工是:**判断位交给 Agent,风险闸门留在代码**——这是标定出来的边界,不是二选一。

平台还承担四组独立复现(各 2160 run)与跨环境重跑(16/16 项一致,不含样本外——S3 样本外重跑已中止,见沙箱执行记录 §7.3);主数据源是本地 8640 run。Replay 是唯一匿名通道,第 ② 项用它留痕。问题、代码与结论均赛中新增。

LLM 判断在 18 个盲态任务上准确率 0.500、7 次冲突全部站代码——这是我们为什么把判断权交给 Agent、把否决权留在代码的实测依据。